Analyse des facteurs qui influencent les accidents de la route

Apprentissage Statistique

Eude Géro
Chloé
Shanice

Master 2 ISIFAR
Université Paris Cité

Année universitaire 2025 - 2026

18 novembre 2025

Table des matières

1 - Introduction

2 - Analyse exploration et tri des données

3 - Modèles

a) Analyse discriminante linéaire
b) Random Forest
c) Régression linéaire

4 - Conclusion

1 - Introduction

Chaque année, des milliers d'accidents corporels sont enregistrés sur le réseau routier français. Si tous ne présentent pas la même gravité, distinguer un accident grave d'un accident non grave constitue un enjeu majeur pour la prévention routière.

Comprendre quels facteurs, liés à l'usager, au véhicule ou à l'environnement, favorisent la survenue d'un accident grave permet d'identifier les situations à risque et d'adapter les mesures de prévention.

Problématique :

> *Quels sont les facteurs qui influencent la gravité d'un accident de la route, et dans quelle mesure peut-on discriminer les accidents graves des accidents non graves à partir de ces variables ?*

Le rapport s'articulera autour des points suivants. Nous présenterons d'abord les données et les transformations que nous avons faites sur le jeu de données, puis nous ferons une analyse des variables afin de faire une présélection des plus pertinentes. Ensuite, nous présenterons les différentes méthodes utilisées pour répondre à notre problématique, avant de les comparer afin de déterminer leur efficacité.

Dans ce projet, nous allons travailler sur la base de données 2024 des accidents corporels de la circulation routière trouvée sur le site Internet www.datagouv.fr . Ces données présentent une vue d'ensemble détaillée des divers éléments qui entrent en considération dans un accident.

Source:
<https://www.data.gouv.fr/datasets/bases-de-donnees-annuelles-des-accidents-corporels-de-la-circulation-routiere-annees-de-2005-a-2024/>

La description des données se trouve directement sur la page, sous forme de pdf, mais nous allons donner des descriptions rapides des variables pertinentes après leur présélection.

2 - Analyse et tri des données

Nous avons choisi de réaliser une ACM pour déterminer les variables les plus pertinentes.

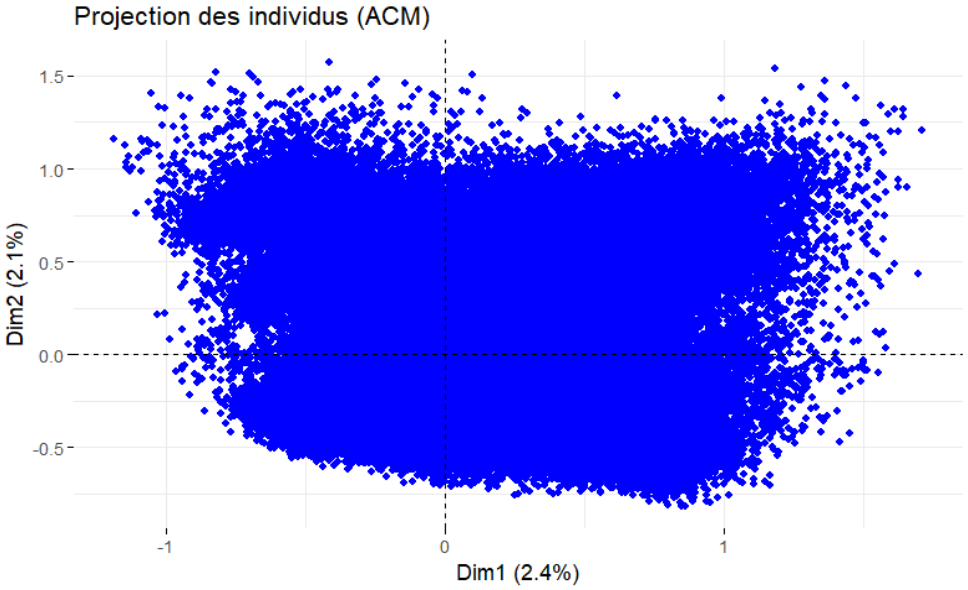

Chaque point représente un accident. Il ressort de l'analyse de ce graphique que la première dimension n'explique que 2.4 % de la variabilité des données. La deuxième dimension explique quant à elle 2.1 % de la variabilité. Alors ces deux axes n'expliquent qu'environ 4.5 % de l'information totale, ce qui n'est pas étonnant vu le nombre de modalités que possèdent certaines variables qualitatives. Le nuage est compact, sans séparation nette: les individus ne se regroupent pas, ce qui est normal sur des données d'accidents très diverses. Donc il n'existe pas de grands profils distincts d'accidents dans l'ensemble de nos données.

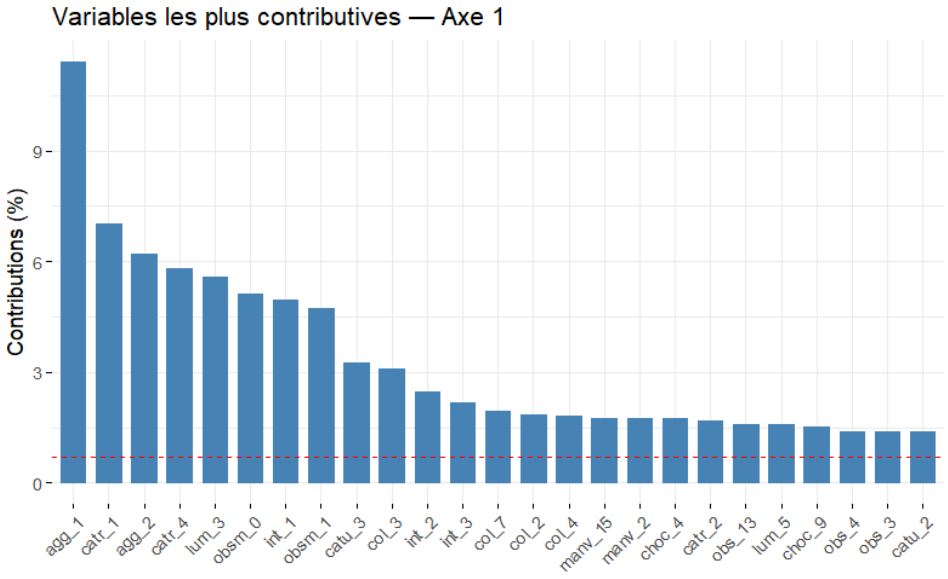

Les contributions montrent quelles variables expliquent le plus la direction du premier axe (Dim1). Les plus importantes sont agg_1 (hors agglomération), catr_1 (autoroute), agg_2 (en agglomération), catr_4 (voie communale), lum_3 (nuit sans éclairage public), obsm_0 (pas d'obstacle mobile heurté), int_1 (hors intersection). Cet axe met en avant le cadre et les conditions générales de survenue des accidents.

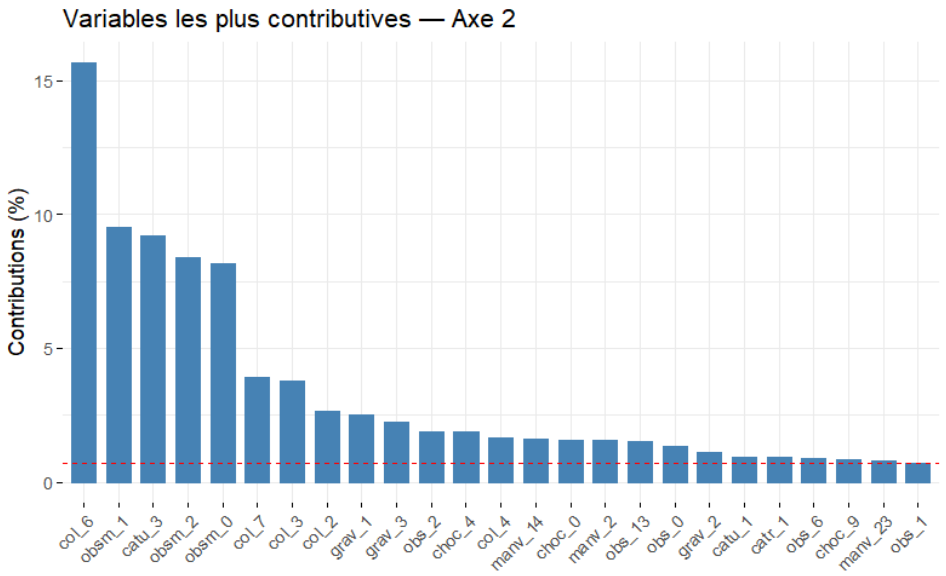

Cet axe met en avant les variables, col_6 (collisions atypiques), obsm_1(piéton heurté), catu_3 (piéton impliqué), obsm_2 (véhicule heurté) et obsm_0 (pas d'obstacle mobile heurté). Il décrit le type d'accident en distinguant les situations impliquant des collisions et obstacles, et ses acteurs.

En conclusion, les variables qualitatives que nous pouvons retenir sont : agg, catr, lum, obsm, obsf, catu, int, col, grav, manv, obs et choc qui traduisent à la fois le contexte, la gravité et la dynamique de l'accident.

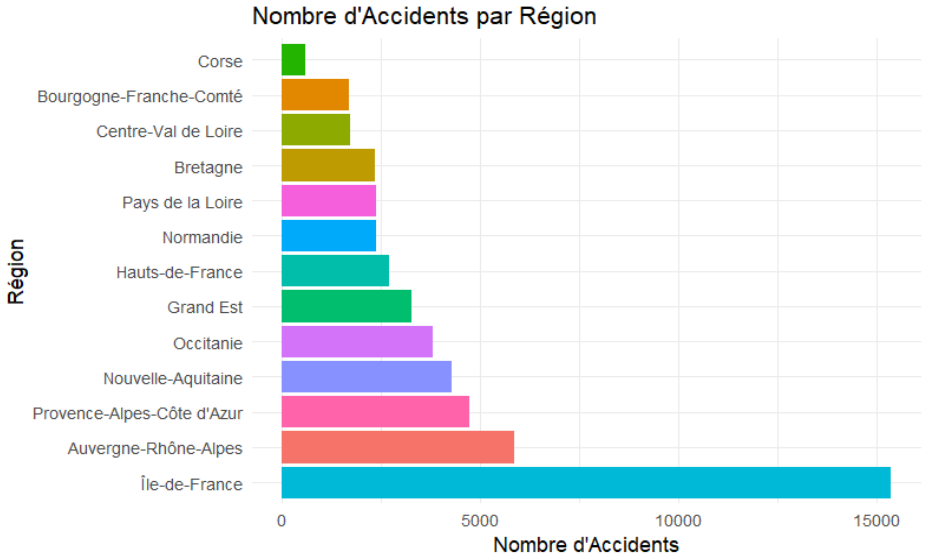

Nous avons ensuite choisi de cibler notre analyse sur une région. La région qui a été retenue est l'Ile-de-France, car c'est celle-ci qui compte le plus d'accidents par région. Une analyse plus poussée nous a également permis une étude à vision départementale. Sans surprise, c'est la ville de Paris qui compte le plus d'accidents en 2024.

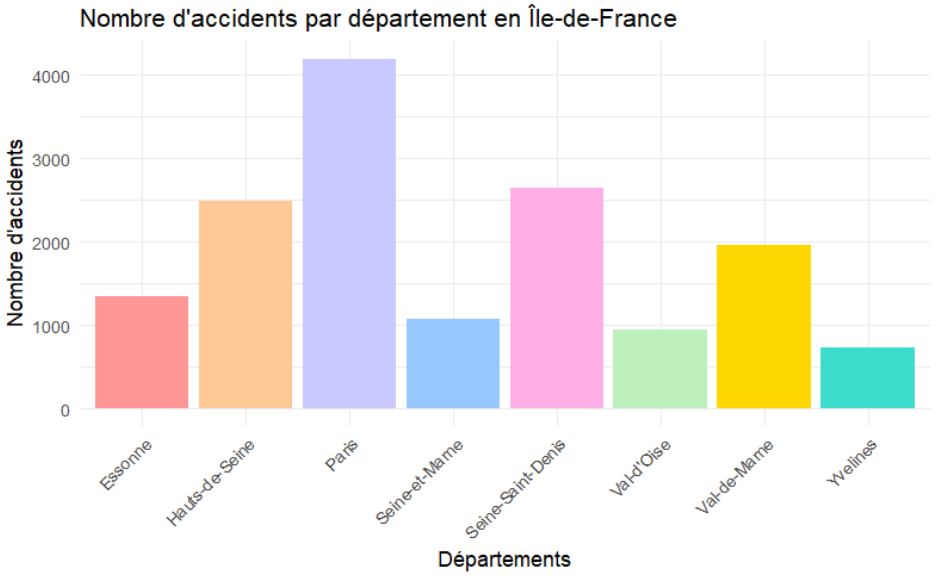

Par la suite, nous avons procédé à la création de notre variable cible. La variable grav comporte initialement 4 niveaux (1=Indemne, 2=Tué, 3=Blessé hospitalisé, 4=Blessé léger). Pour faciliter la modélisation, cette variable est transformée en une variable binaire grav_bin, distinguant les accidents graves des accidents non graves. Donc pour le regroupement on aura: grav_bin: (0=Indemne/Léger, 1=Hospitalisé/Tué).

Ainsi on a pu récupérer de nouvelles informations sur la répartition des accidents par rapport à la gravité.

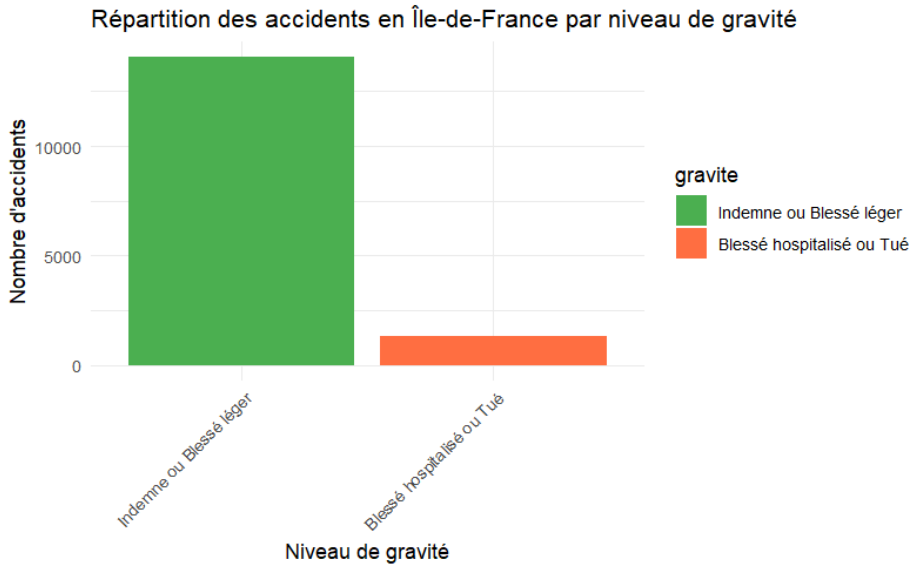

Les accidents graves sont rares, mais cela justifie l'analyse détaillée des facteurs pouvant expliquer la gravité d'un accident. Cette distribution déséquilibrée aura également un impact sur les modèles statistiques que nous allons utiliser.

Après ces premières études sur nos données, nous formulons les hypothèses suivantes:

(H1): Il existe des profils d'accidents distincts identifiables par la classification.
(H2): La vitesse maximale autorisée, les conditions météorologiques et le type de route ont plus d'impact sur le niveau des gravité des accidents de la route.
(H3): Les méthodes d'apprentissage automatique (Random Forest) surpassent les approches linéaires classiques pour la prédiction de la gravité.

3 - Modèles

a) Analyse discriminante linéaire

Pour commencer notre étude prédictive de la gravité des accidents, nous utilisons l'Analyse Discriminante Linéaire (LDA). Cette méthode permet d'identifier les variables qui différencient le mieux deux groupes : ici, les accidents légers (0) et les accidents graves (1). L'objectif de la LDA est de trouver une combinaison linéaire des variables explicatives qui sépare au mieux ces deux catégories, puis d'analyser quelles caractéristiques contribuent le plus à cette séparation.

Avant d'interpréter les coefficients obtenus, on observe d'abord les probabilités a priori fournies par le modèle. La LDA montre un fort déséquilibre entre les groupes: on a environ 9% d'accidents graves contre 91% d'accidents non graves.

Les signes des coefficients du discriminant donnent des indications sur le rôle des variables. Un coefficient positif augmente la probabilité d'un accident grave, alors qu'un coefficient négatif est associée aux accidents non graves.

Les coefficients obtenus nous ont permis d'identifier les facteurs suivants:

- l'âge des usagers: les usagers plus âgés sont légèrement plus souvent impliqués dans des accidents graves.
- les conditions de circulations et de route (vma, surf, catr, prof): plusieurs variables décrivant l'état ou le type de route ressortent comme influentes.
- les conditions d'éclairage (lum): les accidents survenant la nuit, sans éclairage public et par mauvais temps présentent des coefficients positifs.
- les manœuvres à risque (manv): les dépassements, changements de file et manœuvres dangereuses ou inattendues sont retenus comme facteur augmentant la probabilité d'accidents graves.
- les équipements de sécurité (secu): l'absence ou un mauvais usage d'équipement de sécurité est associé à un risque plus important.

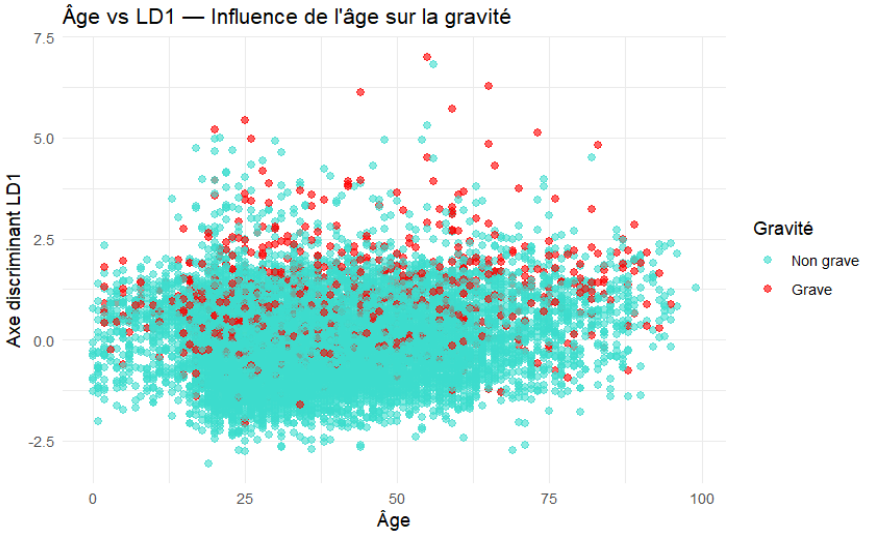

Voici le graphique illustrant la relation entre l'âge et l'axe discriminant LD1 de la LDA. On observe que les accidents graves (points turquoises) ont tendance à apparaître légèrement plus haut sur l'axe LD1, ce qui indique que l'âge joue un rôle modéré dans la gravité.

Toutefois, la séparation reste très faible: à tout âge, on retrouve des accidents graves et non graves. L'âge seul ne permet donc pas de distinguer efficacement les deux catégories, il intervient toujours en combinaison avec les autres variables. On peut observer ci-dessous la proportion d'accidents graves et non graves pour chacune des modalités de la variable surf (surface de la route).

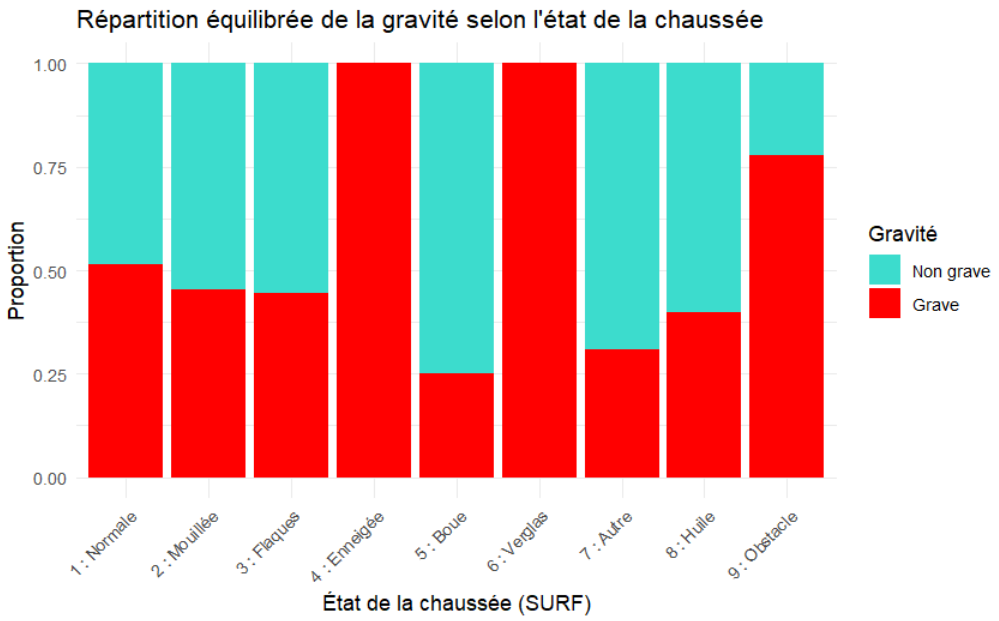

Ce graphique présente la répartition de la gravité des accidents pour chaque type d'état de chaussée, en utilisant un échantillon équilibré (autant d'accidents graves que non graves). Le but est d'évaluer la dangerosité de chaque surface, indépendamment du déséquilibre naturel des données.

On peut observer 3 tendances de répartition:

- Surfaces peu dangereuses (25% d'accidents graves): on remarque une faible proportion d'accidents graves sur les routes boueuses et huilées.
- Surfaces moyennement dangereuses (50% d'accidents graves): les routes normales, mouillées et avec des flaques augmentent le risque d'accidents, mais la répartition reste équilibrée avec les accidents non graves.
- Surfaces très dangereuses: les conditions enneigées, le verglas et la présence d'un obstacle présentent des proportions nettement supérieures d'accidents graves.

Ces observations sont cohérentes avec les résultats de la LDA, la variable surf apparaît comme l'un des facteurs qui contribuent le plus à séparer les accidents

graves des accidents non graves.

Pour évaluer la qualité de la classification donnée par la LDA, nous avons comparé les prédictions du modèle aux valeurs réelles de l'échantillon test.

	Pred 0	Pred 1
Réel 0	2703	25
Réel 1	204	21

La matrice de confusion ci-dessus donne les résultats suivants : le modèle a correctement prédit 2703 accidents non graves et 21 accidents graves, mais il a aussi classé 204 accidents graves comme légers et 25 accidents légers comme graves. Cela donne un taux de bonne classification de 92,2 % qui semble acceptable. Cependant on remarque qu'il n'a su classer correctement que 21 accidents graves sur 225, soit 9,3 %. Donc le modèle est bon pour reconnaître les accidents non graves, mais pas les accidents graves.

On peut visualiser cette conclusion à l'aide du graphique suivant:

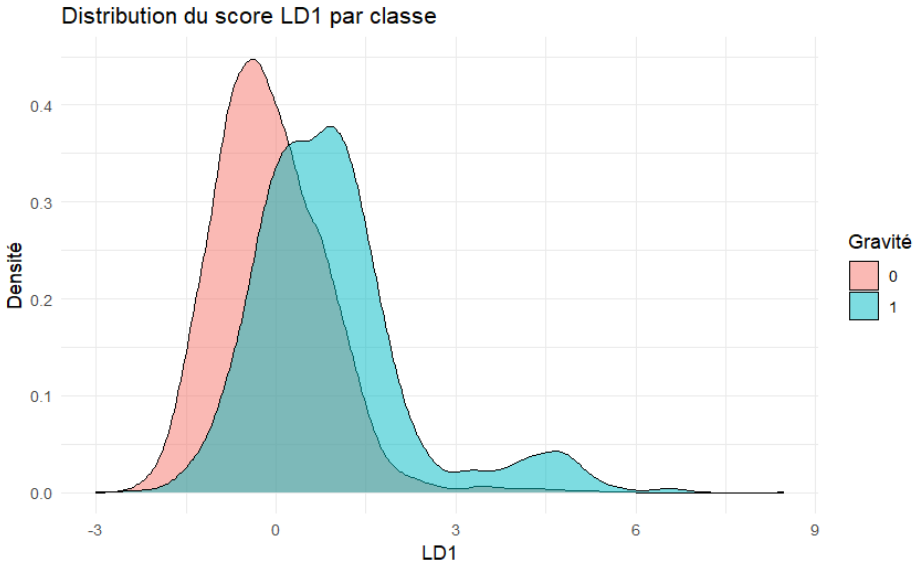

Ce graphique montre la distribution du score discriminant LD1 pour les accidents graves et non graves. On observe que les accidents graves obtiennent en moyenne un score LD1 plus élevé, ce qui signifie que la LDA parvient à distinguer partiellement les 2 groupes. Cependant les distribution se chevauchent fortement, ce qui montre que la séparation n'est pas parfaite et cela explique pourquoi certains accidents graves sont mal classés.

On observe maintenant la courbe ROC et la LDA.

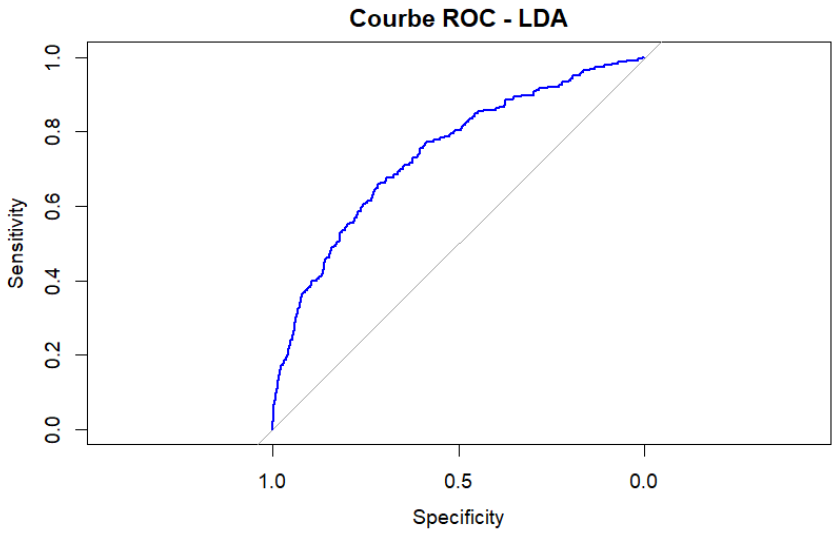

La courbe ROC est principalement au-dessus de la diagonale, ce qui montre que le modèle permet de distinguer les deux classes, mais pas entièrement. Son AUC est d'environ 0.74, ce qui permet de dire que la LDA est un modèle acceptable.

Cela signifie que la LDA arrive à ordonner correctement les accidents selon leur niveau de risque, mais qu'elle reste insuffisante pour détecter les accidents graves, surtout si les données sont déséquilibrées.

b) Random Forest

Nous avons ensuite utilisé la méthode Random Forest et avons pu en tirer les résultats suivants:

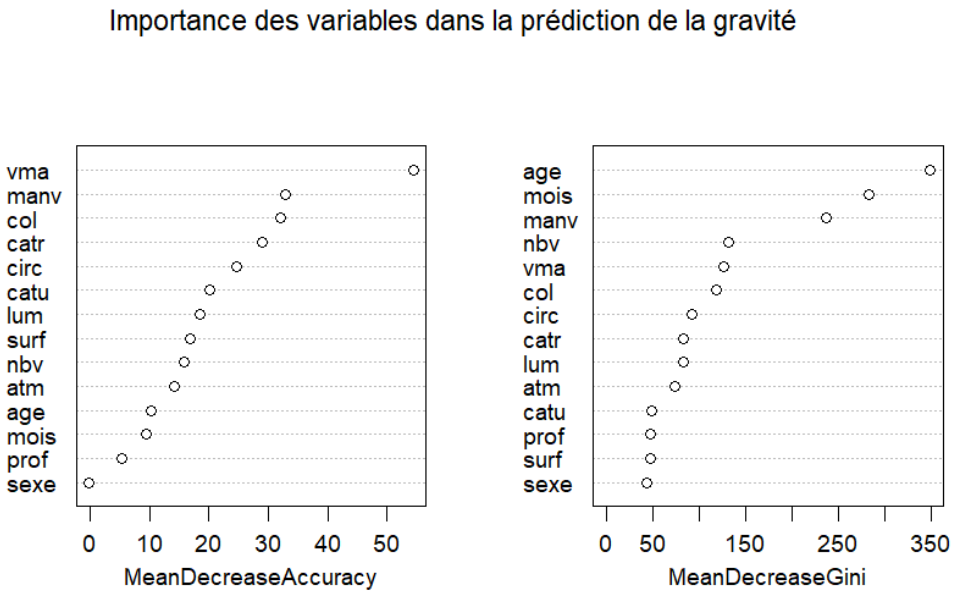

Sur le graphe de gauche, on voit que les variables manoeuvre (manv), vitesse (vma) et catégorie de la route (catr) ont de l'importance dans la précision de notre modèle. Cela montre qu'en utilisant la combinaison de ces quatre métriques, on peut ajuster la prédiction de la gravité d'un accident. Il est aussi évident que les usagers de la route ont plus de risque d'avoir un grave accident lorsqu'ils empruntent un certain type de voie à grande vitesse ou font de fausses manœuvres (mauvais usage de la route).

Sur celui de droite, on remarque que les facteurs âge, manoeuvre et mois de l'accident sont de forts indicateurs de la gravité de l'accident. Ils permettent réellement de le prédire.

La matrice de confusion obtenue sur l'échantillon test est la suivante :

	Pred 0	Pred 1
Réel 0	2714	14
Réel 1	209	16

Le modèle affiche un taux de bonne classification de 92,45%, ce qui montre que les métriques qu'on a citées précédemment ont un réel impact sur la sévérité des accidents de la route. Cependant, une analyse détaillée montre une forte différence entre les deux classes. Les accidents non graves sont très bien reconnus et les accidents graves sont mal détectés, seulement 7,1% ont été correctement prédits.. Cette méthode détecte mieux les accidents non graves que la LDA, mais elle reconnaît cependant moins bien les accidents graves.

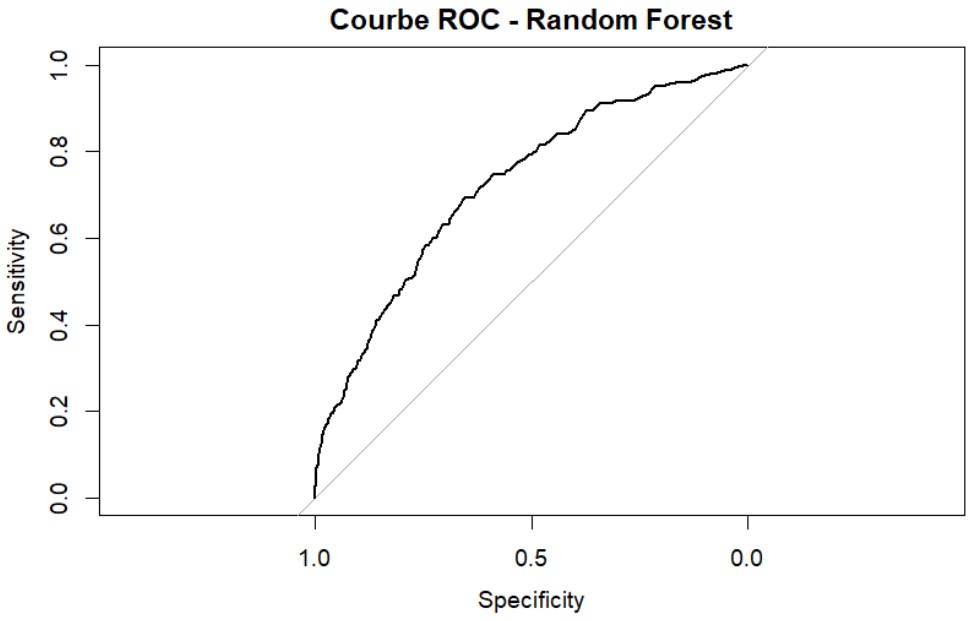

Comme pour la LDA, la courbe se situe au-dessus de la diagonale. Son AUC est de 0.72, ce qui est légèrement plus bas que le précédent modèle.

L'indicateur Mean Decrease Gini nous a ainsi permis de relever les 10 variables qui influencent le plus la gravité des accidents.

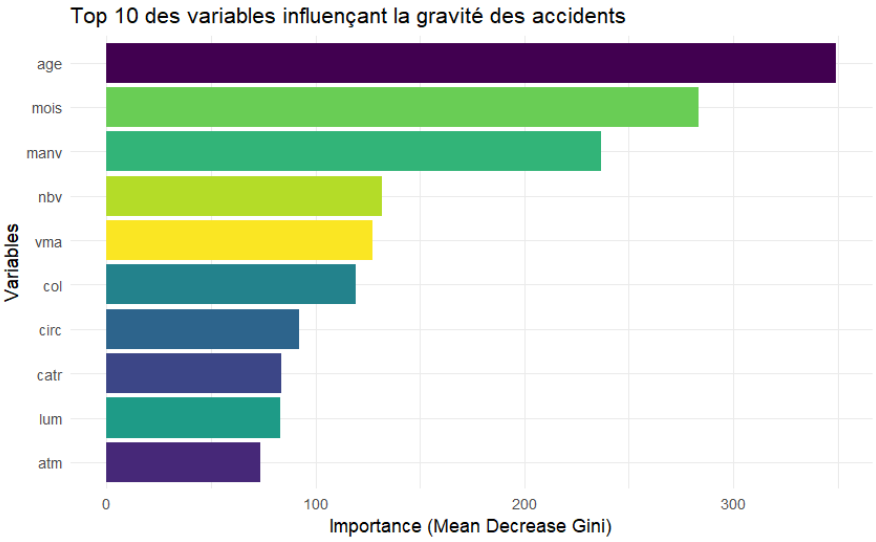

Ces résultats soulignent que la gravité d'un accident dépend à la fois de facteurs humains (âge), de facteurs comportementaux (manœuvres) et de facteurs liés à l'environnement routier. Le Random Forest confirme donc les mêmes tendances que la LDA, tout en mettant en lumières d'autres variables qui influencent la gravité d'un accident.

c) Régression logistique

Dans notre étude, la gravité de l'accident est binaire. Pour analyser ce type de variable, on utilise la régression logistique. Ce modèle statistique estime la probabilité qu'un accident soit grave en fonction de différentes caractéristiques. Chaque coefficient du modèle indique si une variable augmente ou diminue le risque d'accident grave.

Parmi les variables qui augmentent le risque d'accident grave, on retrouve:

- la vitesse autorisée: Les vitesses élevées sont clairement associées à un risque plus important. Les coefficients positifs indiquent qu'à partir de 80 km/h, la probabilité d'un accident grave est multipliée par 4 à 6 par rapport à une zone 50 km/h.

- la catégorie de la route (catr): Les routes communales et départementales sont plus propices aux accidents que les routes nationales; les autoroutes offrent

une meilleure sécurité structurelle, mais les accidents qui s'y produisent sont souvent plus graves à cause de la vitesse.

- le profil de la route (prof): Le relief de la route joue également un rôle. Les zones en pente augmentent la probabilité d'un accident grave; les zones plates tendent à encourager la hausse de la vitesse, ce qui renforce le risque.

- les conditions de luminosité (lum): Les accidents survenant la nuit, au crépuscule ou à l'aube sont significativement plus graves que ceux survenant le jour. La probabilité d'un accident grave est en moyenne 1,6 fois plus élevée en faible luminosité.

- l'âge et la catégorie d'usager (age, catu): Les jeunes conducteurs et les personnes âgées présentent un plus grand risque d'accidents graves. Les piétons et passagers sont plus vulnérables que les autres catégories d'usagers.

On peut noter que les conditions atmosphériques (atm) et le sexe des individus n'ont pas d'effet significatif sur la gravité d'un accident.

Après avoir identifié les variables influençant la probabilité qu'un accident soit grave, il est nécessaire d'évaluer la capacité prédictive réelle du modèle. Pour cela, nous utilisons la courbe ROC, qui permet de mesurer dans quelle mesure la régression logistique distingue les accidents graves des accidents non graves.

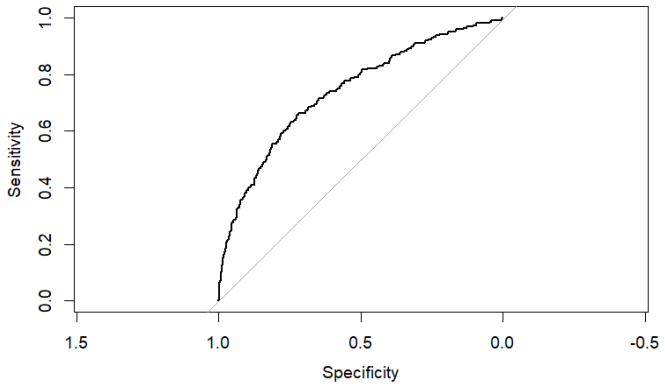

La courbe ROC du modèle présente une AUC d'environ 0,74, ce qui montre que la régression logistique arrive dans une moindre mesure à distinguer les accidents graves des non graves. Le taux de bonne classification s'élève à 92,52%, ce qui peut paraître satisfaisant, mais cela est probablement dû au fait que les accidents graves sont minoritaires dans le jeu de données.

La matrice de confusion confirme ce déséquilibre:

	Pred 0	Pred 1
Réel 0	2721	7
Réel 1	214	11

En effet, celle-ci montre que parmi les accidents non graves, 2721 ont été correctement prédits contre 7 ont été mal classés, alors que parmi les accidents graves, seulement 11 ont été bien prédits contre 214 mal classés. Le modèle est donc très fiable pour les cas fréquents.

Nous pouvons visualiser cette classification au moyen du graphique suivant :

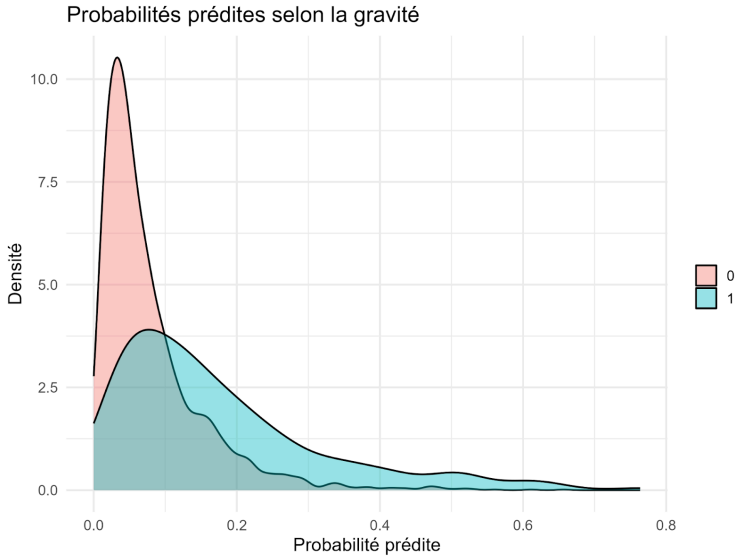

On voit que le modèle attribue en général des probabilités plus élevées aux situations graves alors que les cas non graves se concentrent plutôt vers des probabilités plus petites. La séparation observée au niveau des deux courbes nous montre que le modèle fait bien la différence entre les deux types de situations. Le chevauchement nous indique par contre que certains cas sont moins distinguables.

4 - Conclusion

Dans le cadre de ce projet, nous avons examiné plus de 15000 accidents corporels en Ile-de-France et travaillé sur les éléments qui peuvent expliquer ou anticiper la gravité d'un accident. Suite à un processus de nettoyage, de recodage, de visualisation et de choix des variables, nous avons estimé quatres différents modèles. Le modèle de régression logistique, l'analyse linéaire discriminante, le Lasso et le Random Forest. Les résultats nous indiquent que la régression logistique est le plus performant, fournissant un meilleur équilibre entre la précision, la stabilité et la capacité d'interprétation des données. Ce modèle met en exergue l'importance cruciale de plusieurs facteurs comme les conditions climatiques, le genre de conduite, l'action effectuée au moment de l'accident, les conditions d'éclairages et même l'âge des usagers. Quant au modèle Lasso, il souligne l'importance de ces éléments en maintenant un groupe cohérent de variables, bien que ses performances soient légèrement moindres. Pour ce qui est de l'analyse linéaire discriminante, il demeure le modèle le moins approprié à cause de ses hypothèses.

Par ailleurs, les résultats trouvés après estimations nous permettent de confirmer les hypothèses 1 et de 2 puis d'infirmer l'hypothèse 3 qui stipule que les méthodes d'apprentissage automatique comme le Random Forest surpassent les approches linéaires classiques pour la prédiction de la gravité.

Globalement, nous pouvons conclure que la gravité d'un accident n'est pas seulement liée à un facteur isolé, mais dépend d'une combinaison de conditions. Ce travail offre aussi des opportunités prometteuses pour améliorer la prédiction, en particulier grâce à l'utilisation des modèles plus spécifiques ou l'intégration de nouvelles variables. Les travaux futurs pourront donc prendre en compte ces éléments pour mieux prédire la gravité des accidents et relever d'autres facteurs que l'on pourrait améliorer pour limiter la gravité des accidents.